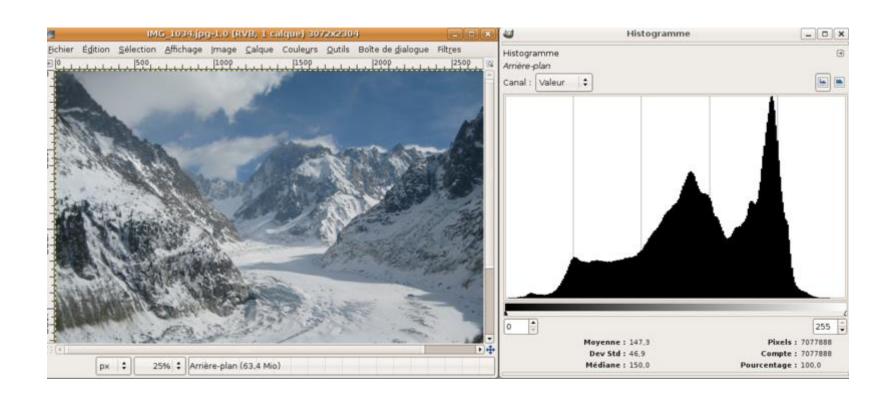
Лекция 12 Технология CUDA

Курносов Михаил Георгиевич

E-mail: mkurnosov@gmail.com WWW: www.mkurnosov.net

Курс «Высокопроизводительные вычислительные системы» Сибирский государственный университет телекоммуникаций и информатики (Новосибирск) Осенний семестр, 2015

Гистограмма цветов изображения



- Задано изображение двумерный массив целых чисел из интервала [0..255]
- Необходимо построить гистограмму, таблицу hist[0..255], элемент hist[i] которой равен числу пикселей с цветом і

Гистограмма цветов изображения (CPU)

```
// Выделение памяти под изображение
size t size = sizeof(uint8 t) * width * height;
uint8 t *image = (uint8 t *)malloc(size);
if (image == NULL) {
    fprintf(stderr, "Allocation error.\n");
    exit(EXIT FAILURE);
// Инициализация изображения
srand(0);
for (size t i = 0; i < size; i++)</pre>
    image[i] = (rand() / (double)RAND MAX) * 255;
// Инициализация гистограммы
int hist[256];
memset(hist, 0, sizeof(*hist) * 256);
```

Гистограмма цветов изображения (CPU)

Нерегулярный шаблон доступа к памяти массиву hist

Гистограмма цветов изображения (GPU)

Каждый поток обрабатывает один пиксель изображения

```
// Гистограмма в памяти GPU
int *d hist = NULL;
cudaMalloc((void **)&d_hist, sizeof(*d_hist) * 256);
cudaMemset(d hist, 0, sizeof(*d hist) * 256);
uint8 t *d image = NULL;
cudaMalloc((void **)&d image, size);
cudaMemcpy(d image, image, size, cudaMemcpyHostToDevice);
int threadsPerBlock = 1024;
int blocksPerGrid = (size + threadsPerBlock - 1) / threadsPerBlock;
hist gpu<<<blocksPerGrid, threadsPerBlock>>>(d_image, width,
                                             height, d hist);
cudaMemcpy(hist, d_hist, sizeof(*d_hist) * 256, cudaMemcpyDeviceToHost);
```

Гистограмма цветов изображения (GPU)

Каждый поток обрабатывает один пиксель изображения

Гистограмма цветов изображения: тест

```
$ ./hist
Sum (CPU) = 104857600.000000
CUDA kernel launch with 102400 blocks of 1024 threads
Sum (GPU) = 3928061.000000
CPU version (sec.): 0.052969
GPU version (sec.): 0.068165
Memory ops. (sec.): 0.000019
Speedup: 0.78
Speedup (with mem ops.): 0.78
$ ./hist
Sum (CPU) = 104857600.000000
CUDA kernel launch with 102400 blocks of 1024 threads
Sum (GPU) = 3931478.000000
CPU version (sec.): 0.052965
GPU version (sec.): 0.068171
Memory ops. (sec.): 0.000020
Speedup: 0.78
Speedup (with mem ops.): 0.78
```

Гистограмма цветов изображения (GPU)

Каждый поток обрабатывает один пиксель изображения

Потоки одновременно читают и записывают данные в одни и те же ячейки таблицы hist[0..255] – data race

CUDA Atomic Functions

Атомарная функция (CUDA atomic function) — функция, выполняющая операцию read-modify-write (RMW) над 32 или 64 битным значением в глобальной или разделяемой памяти GPU

atomicAdd для double (CAS-based)

```
_device___ double atomicAdd(double* address, double val)
  unsigned long long int* addr = (unsigned long long int*)address;
  unsigned long long int old = *addr, assumed;
  do {
      assumed = old;
      old = atomicCAS(addr, assumed,
                        double as longlong(val +
                        longlong as_double(assumed)));
  } while (assumed != old);
                                              int atomicCAS(int* address, int compare, int val);
  return __longlong_as_double(old);
                                             1. Загружает в old значение по адресу address
                                             2. Записывает обратно значение:
                                                (old == compare) ? val : old
                                             3. Возвращает old
```

Гистограмма цветов изображения (GPU)

Гистограмма цветов изображения (GPU)

```
_global__ void hist_gpu_atomic(uint8_t *image, int width,
                                int height, int *hist)
   size t size = width * height;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   int stride = blockDim.x * gridDim.x;
  while (i < size) {</pre>
       atomicAdd(&hist[image[i]], 1);
       i += stride;
```

Если пикселей больше числа потоков

Редукция (reduction)

- Задан массив v[0..n-1] из n элементов и ассоциативная операция \otimes
- Необходимо вычислить результаты редукции

$$r = v[0] \otimes v[1] \otimes ... \otimes v[n-1]$$

• Пример:

$$v[0..5] = [5, 8, 3, 12, 1, 7]$$

 $r = ((((5 + 8) + 3) + 12) + 1) + 7 = 36$

Последовательная версия (float)

```
void reduce_cpu(float *v, int n, float *sum)
    float s = 0.0;
    for (int i = 0; i < n; i++)
        s += v[i];
    *sum = s;
int n = 10000;
for (size t i = 0; i < n; i++)
   v[i] = i + 1.0;
```

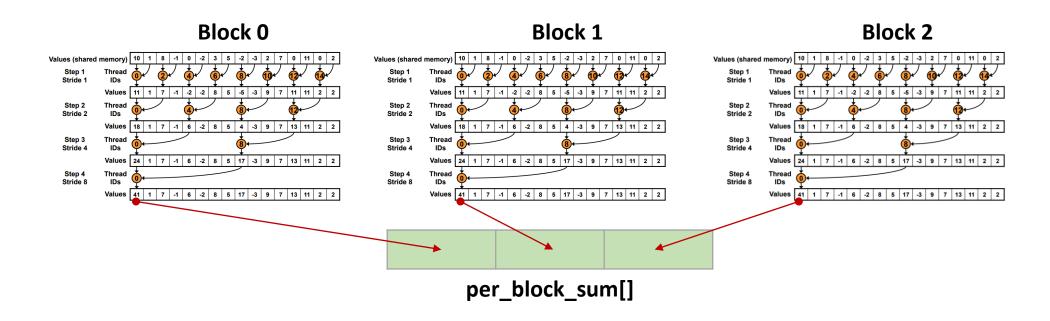
reduce cpu(v, n, &sum);

- Floating-point Summation // http://www.drdobbs.com/floating-point-summation/184403224
- David Goldberg. What Every Computer Scientist Should Know About Floating-Point Arithmetic // ACM Computing Surveys, Vol. 23, #1, March 1991, pp. 5-48.

```
# Real sum = 50005000
Sum (CPU) = 50002896.000000, err = 2104.000000
```

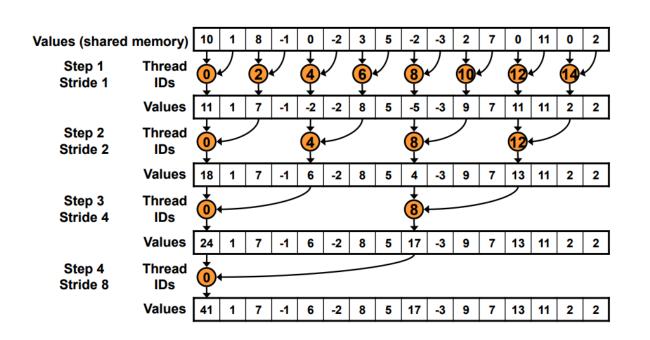
Последовательная версия (int)

```
void reduce_cpu(int *v, int n, int *sum)
{
    int s = 0.0;
    for (int i = 0; i < n; i++)
        s += v[i];
    *sum = s;
}</pre>
```



- Каждый блок потоков обрабатывает часть массива v[0..n 1]
- Поток 0 каждого блока сохраняет результат редукции в массив per_block_sum[0..blocks 1]
- Для выполнения редукции массива per_block_sum[] нужен еще один шаг на GPU или CPU:

```
cudaMemcpy(sums, per_block_sum, sizeof(int) * blocks, cudaMemcpyDeviceToHost);
int sum_gpu = 0;
for (int i = 0; i < blocks; i++)
    sum_gpu += sums[i];</pre>
```



```
for (int s = 1; s < blockDim.x; s *= 2) {
   if (tid % (2 * s) == 0)
      sdata[tid] += sdata[tid + s];
}</pre>
```

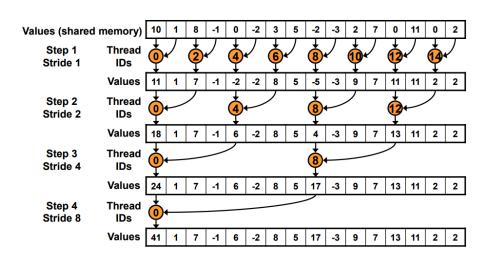
- Каждый поток по своему номеру tid определяет с кем ему взаимодействовать
- На шаге 1 каждый 2-й поток взаимодействует с соседом справа на расстоянии s = 1
- На шаге 2 каждый 4-й поток взаимодействует с соседом справа на расстоянии s = 2
- На шаге 3 каждый 8-й поток взаимодействует с соседом справа на расстоянии s = 4
- **-** ...
- Всего шагов O(logn)

```
const int block size = 1024;
const int n = 4 * (1 << 20);
int main()
    size t size = sizeof(int) * n;
    int *v = (int *)malloc(size);
    for (size t i = 0; i < n; i++)
       v[i] = i + 1;
    int sum;
   reduce cpu(v, n, &sum);
    /* Allocate on device */
    int threads per block = block size;
    int blocks = (n + threads per block - 1) / threads per block;
    int *dv, *per block sum;
    int *sums = (int *)malloc(sizeof(int) * blocks);
    tmem = -wtime();
    cudaMalloc((void **)&per_block_sum, sizeof(int) * blocks);
    cudaMalloc((void **)&dv, size);
    cudaMemcpy(dv, v, size, cudaMemcpyHostToDevice);
    tmem += wtime();
```

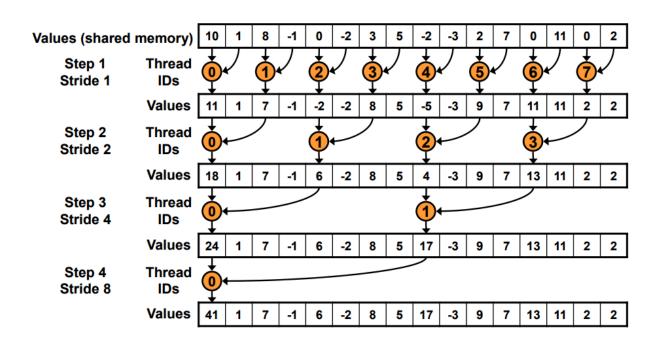
```
/* Compute per block sum: stage 1 */
tgpu = -wtime();
reduce_per_block<<<blocks, threads_per_block>>>(dv, n, per_block_sum);
cudaDeviceSynchronize();
tgpu += wtime();
tmem = -wtime();
cudaMemcpy(sums, per block sum, sizeof(int) * blocks, cudaMemcpyDeviceToHost);
tmem += wtime();
/* Compute block sum: stage 2 */
tgpu -= wtime();
int sum gpu = 0;
for (int i = 0; i < blocks; i++)</pre>
    sum gpu += sums[i];
tgpu += wtime();
printf("CPU version (sec.): %.6f\n", tcpu);
printf("GPU version (sec.): %.6f\n", tgpu);
printf("GPU bandwidth (GiB/s): %.2f\n", 1.0e-9 * size / (tgpu + tmem));
printf("Speedup: %.2f\n", tcpu / tgpu);
printf("Speedup (with mem ops.): %.2f\n", tcpu / (tgpu + tmem));
```

```
_global__ void reduce_per_block(int *v, int n, int *per_block_sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
                                                                         Values (shared memory)
   int i = blockIdx.x * blockDim.x + threadIdx.x;
                                                                                  Thread
                                                                           Stride 1
   if (i < n) {
                                                                                  Thread
                                                                           Step 2
                                                                           Stride 2
         sdata[tid] = v[i];
                                                                                              6 | -2 | 8 | 5 | 4 | -3 | 9 | 7 | 13 | 11 | 2 | 2
                                                                           Step 3
                                                                                  Thread
         syncthreads();
                                                                           Stride 4
                                                                                          7 | -1 | 6 | -2 | 8 | 5 | 17 | -3 | 9 | 7 | 13 | 11 | 2 | 2
                                                                                  Values
                                                                                 Thread
         for (int s = 1; s < blockDim.x; s *= 2) {</pre>
                                                                           Stride 8
              if (tid \% (2 * s) == 0)
                   sdata[tid] += sdata[tid + s];
              syncthreads();
                                                                        CUDA kernel launch with 4096 blocks of 1024 threads
                                                                        Sum (CPU) = 2097152
         if (tid == 0)
                                                                        Sum (GPU) = 2097152
              per_block_sum[blockIdx.x] = sdata[0];
                                                                        CPU version (sec.): 0.005956
                                                                        GPU version (sec.): 0.002198
                                                                        GPU bandwidth (GiB/s): 7.56
                                                                        Speedup: 2.71
                                                                        Speedup (with mem ops.): 2.68
```

```
_global__ void reduce_per_block(int *v, int n, int *per_block_sum)
  shared int sdata[block size];
  int tid = threadIdx.x;
  int i = blockIdx.x * blockDim.x + threadIdx.x;
  if (i < n) {
      sdata[tid] = v[i];
      __syncthreads();
      for (int s = 1; s < blockDim.x; s *= 2) {</pre>
          if (tid \% (2 * s) == 0)
              sdata[tid] += sdata[tid + s];
          syncthreads();
      if (tid == 0)
          per_block_sum[blockIdx.x] = sdata[0];
```



Результат условия зависит от номера потока — часть потоков деактивируется (control flow divergence)

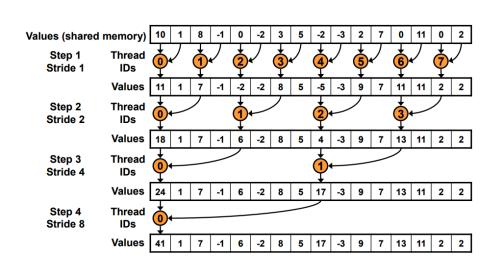


Control flow divergence!

```
for (int s = 1; s < blockDim.x; s *= 2) {
    if (tid % (2 * s) == 0)
        sdata[tid] += sdata[tid + s];
    __syncthreads();
}</pre>
```

```
for (int s = 1; s < blockDim.x; s *= 2) {
   int index = 2 * s * tid;
   if (index < blockDim.x)
       sdata[index] += sdata[index + s];
       __syncthreads();
}</pre>
```

```
global void reduce per block(int *v, int n, int *per block sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {
       sdata[tid] = v[i];
       __syncthreads();
       for (int s = 1; s < blockDim.x; s *= 2) {</pre>
           int index = 2 * s * tid;
           if (index < blockDim.x)</pre>
               sdata[index] += sdata[index + s];
           syncthreads();
       if (tid == 0)
           per block sum[blockIdx.x] = sdata[0];
```



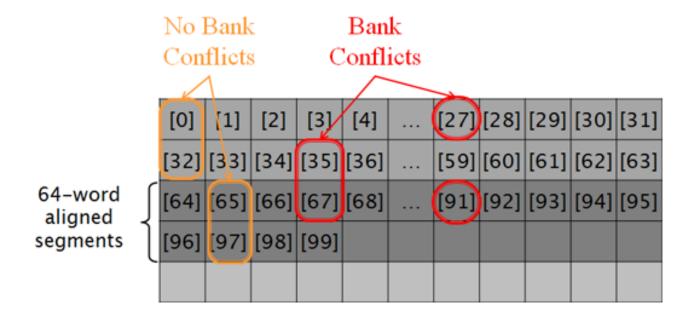
```
CUDA kernel launch with 4096 blocks of 1024 threads Sum (CPU) = 2097152
Sum (GPU) = 2097152
CPU version (sec.): 0.006481
GPU version (sec.): 0.001968
GPU bandwidth (GiB/s): 8.44
Speedup: 3.29
Speedup (with mem ops.): 3.26
```

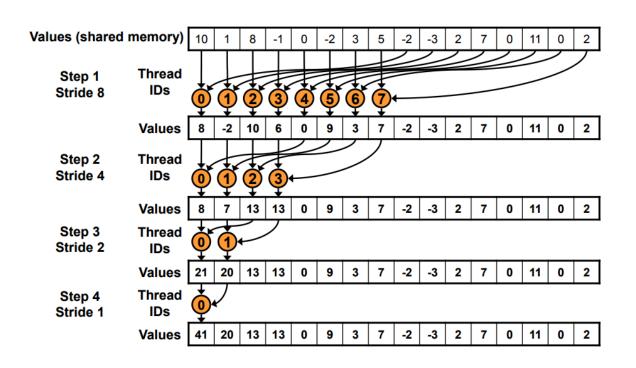
```
global void reduce per block(int *v, int n, int *per block sum)
   shared int sdata[block size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {</pre>
       sdata[tid] = v[i];
       __syncthreads();
       for (int s = 1; s < blockDim.x; s *= 2) {</pre>
           int index = 2 * s * tid;
           if (index < blockDim.x)</pre>
               sdata[index] += sdata[index + s];
           syncthreads();
       if (tid == 0)
           per_block_sum[blockIdx.x] = sdata[0];
```

- Обращение к разделяемой памяти выполняется через 32 параллельно функционирующих банка
- Каждый банк 4 байта (настраивается)
- Номер банка = адрес % 32
- Одновременный доступ к одному банку сериализуется!

TID	S = 1	S = 2	S = 4
0	0-1 // banks 0, 1	0-2 // banks 0, 1	0-4 // banks 0, 1
1	2-3 // banks 2, 3	4-6 // banks 2, 3	
2	4-5 // banks 4, 5	8-10 // banks 4, 5	
3	6-7 // banks 6, 7	12-14 // banks 6, 7	24-28 // banks 24, 28
4	8-9 // banks 8, 9	16-18 // banks 8, 9	32-36 // banks 0, 2
8		32-34 // banks 0, 2	
9		36-38 // banks 4, 6	

Shared memory bank conflicts

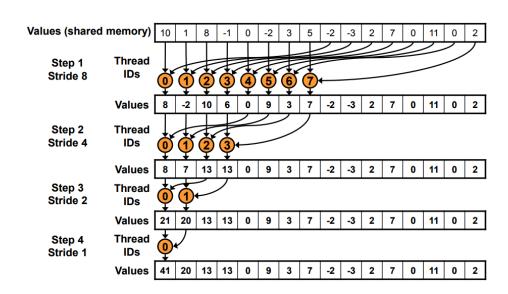




Bank conflicts

```
for (int s = 1; s < blockDim.x; s *= 2) {
   int index = 2 * s * tid;
   if (index < blockDim.x)
       sdata[index] += sdata[index + s];
       __syncthreads();
}</pre>
for (int s = blockDim.x / 2; s > 0; s >>= 1) {
   if (tid < s)
       sdata[tid] += sdata[tid + s];
       __syncthreads();
}</pre>
```

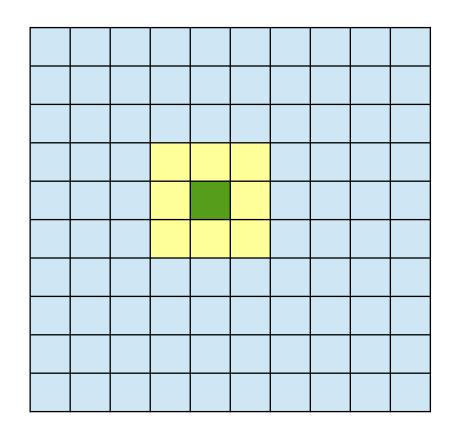
```
__global__ void reduce_per_block(int *v, int n, int *per_block_sum)
   __shared__ int sdata[block_size];
   int tid = threadIdx.x;
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i < n) {
       sdata[tid] = v[i];
       syncthreads();
       for (int s = blockDim.x / 2; s > 0; s >>= 1) {
           if (tid < s)
               sdata[tid] += sdata[tid + s];
           syncthreads();
       if (tid == 0)
           per block sum[blockIdx.x] = sdata[0];
```



```
CUDA kernel launch with 4096 blocks of 1024 threads Sum (CPU) = 2097152
Sum (GPU) = 2097152
CPU version (sec.): 0.004661
GPU version (sec.): 0.001163
GPU bandwidth (GiB/s): 14.17
Speedup: 4.01
Speedup (with mem ops.): 3.94
```

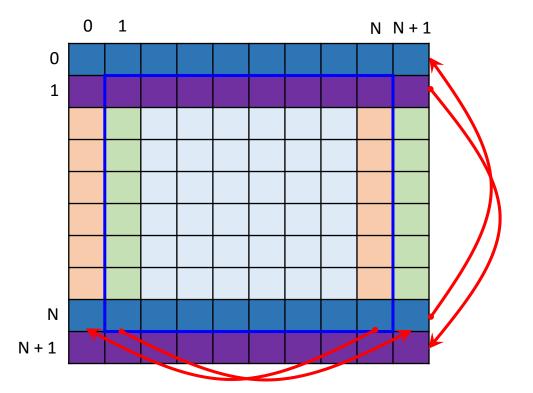
Conway's Game of Life

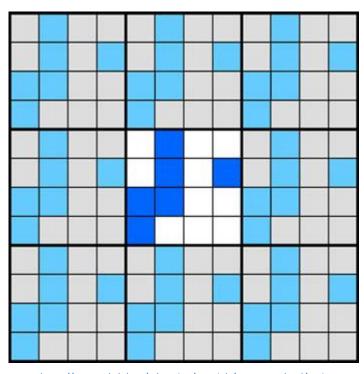
- **Игра «Жизнь»** (Game of Life, Дж. Конвей, 1970)
- Игровое поле размеченная на клетки плоскость
- Каждая клетка может находиться в двух состояниях:
 «живая» и «мёртвая», и имеет восемь соседей
- Распределение живых клеток в начале игры называется первым поколением. Каждое следующее поколение рассчитывается на основе предыдущего:
 - 1) в мертвой клетке, рядом с которой три живые клетки, зарождается жизнь
 - 2) если у живой клетки есть две или три живые соседки, то эта клетка продолжает жить; в противном случае (соседей < 2 или > 3) клетка умирает



Периодические граничные условия (periodic boundary conditions)

- Как вычислять состояния граничных ячеек (ячеек слева, справа, снизу, сверху может не существовать)?
- Одно из решений периодические граничные условия (periodic boundary conditions)
- Игровое поле бесконечно продолжается по всем направлениям
- В массиве требуется хранить теневые ячейки (ghost cells, shadow cells)

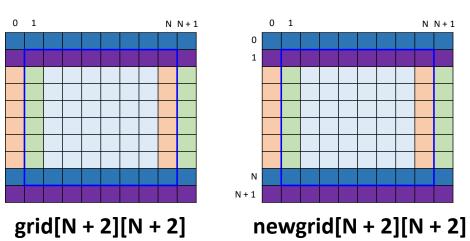




https://www.pdc.kth.se/education/tutorials/summer-school/mpiexercises/mpi-lab-1-program-structure-and-point-to-point-communicationin-mpi/background-for-the-game-of-life

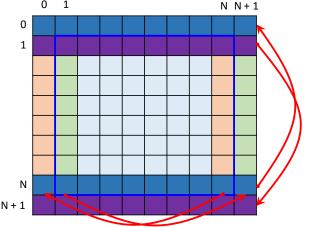
Последовательная реализация (1_gol/gol.c)

```
#define IND(i, j) ((i) * (N + 2) + (j))
enum {
    N = 1024
    ITERS MAX = 1 << 10
};
typedef uint8 t cell t;
int main(int argc, char* argv[])
    // Grid with periodic boundary conditions (ghost cells)
    size t ncells = (N + 2) * (N + 2);
    size t size = sizeof(cell t) * ncells;
    cell_t *grid = malloc(size);
    cell t *newgrid = malloc(size);
    // Initial population
    srand(0);
    for (int i = 1; i <= N; i++)
        for (int j = 1; j <= N; j++)</pre>
            grid[IND(i, j)] = rand() \% 2;
```



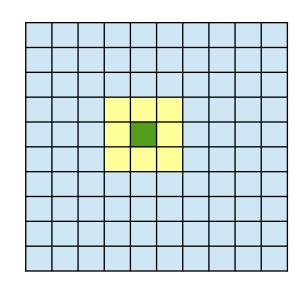
Последовательная реализация (продолжение)

```
double t = wtime();
int iter;
for (iter = 0; iter < ITERS_MAX; iter++) {</pre>
   // Copy ghost columns
   for (int i = 1; i <= N; i++) {
       grid[IND(i, 0)] = grid[IND(i, N)];  // left ghost column
       grid[IND(i, N + 1)] = grid[IND(i, 1)]; // right ghost column
   // Copy ghost rows
   for (int i = 0; i <= N + 1; i++) {
       grid[IND(0, i)] = grid[IND(N, i)];  // top ghost row
       grid[IND(N + 1, i)] = grid[IND(1, i)]; // bottom ghost row
```



Последовательная реализация (продолжение)

```
for (int i = 1; i <= N; i++) {
        for (int j = 1; j <= N; j++) {
            int nneibs = grid[IND(i + 1, j)] + grid[IND(i - 1, j)] +
                         grid[IND(i, j + 1)] + grid[IND(i, j - 1)] +
                         grid[IND(i + 1, j + 1)] + grid[IND(i - 1, j - 1)] +
                         grid[IND(i - 1, j + 1)] + grid[IND(i + 1, j - 1)];
            cell_t state = grid[IND(i, j)];
            cell t newstate = state;
            if (state == 1 && nneibs < 2)</pre>
                newstate = 0;
            else if (state == 1 && (nneibs == 2 || nneibs == 3))
                newstate = 1;
            else if (state == 1 && nneibs > 3)
                newstate = 0;
            else if (state == 0 && nneibs == 3)
                newstate = 1;
            newgrid[IND(i, j)] = newstate;
    cell t *p = grid; grid = newgrid; newgrid = p;
t = wtime() - t;
```



Последовательная реализация (окончание)

```
size t total = 0;
for (int i = 1; i <= N; i++) {
    for (int j = 1; j <= N; j++)
        total += grid[IND(i, j)];
printf("Game of Life: N = %d, iterations = %d\n", N, iter);
printf("Total alive cells: %lu\n", total);
printf("Iters per sec.: %.2f\n", iter / t);
printf("Total time (sec.): %.6f\n", t);
free(grid);
free(newgrid);
return 0;
```

Cluster Oak / cngpu1 (Intel Core i5-3320M)

```
Game of Life: N = 1024, iterations = 1024
Total alive cells: 47026
Iters per sec.: 280.05
Total time (sec.): 3.656496
```

Модификация последовательной реализации (2_gol_state)

```
int states[2][9] = {
    {0, 0, 0, 1, 0, 0, 0, 0}, /* New states for a dead cell */
    {0, 0, 1, 1, 0, 0, 0, 0} /* New states for an alive cell */
};
for (int i = 1; i <= N; i++) {
    for (int j = 1; j <= N; j++) {
         int nneibs = grid[IND(i + 1, j)] + grid[IND(i - 1, j)] +
                     grid[IND(i, j + 1)] + grid[IND(i, j - 1)] +
                     grid[IND(i + 1, j + 1)] + grid[IND(i - 1, j - 1)] +
                     grid[IND(i - 1, j + 1)] + grid[IND(i + 1, j - 1)];
        cell t state = grid[IND(i, j)];
        newgrid[IND(i, j)] = states[state][nneibs];
```

Cluster Oak / cngpu1 (Intel Core i5-3320M)

```
Game of Life: N = 1024, iterations = 1024

Total alive cells: 47026

Iters per sec.: 448.07

Total time (sec.): 2.285372

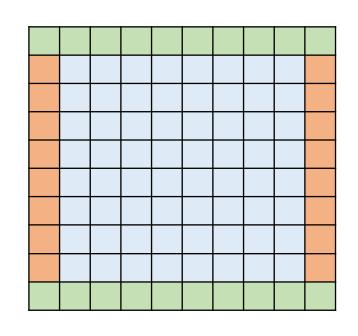
Speedup x1.6
```

```
#define IND(i, j) ((i) * (N + 2) + (j))
enum {
   N = 1024
    ITERS_MAX = 1 << 10,
    BLOCK_SIZE = 16
};
typedef uint8 t cell t;
int main(int argc, char* argv[])
    // Grid with periodic boundary conditions (ghost cells)
    size t ncells = (N + 2) * (N + 2);
    size_t size = sizeof(cell_t) * ncells;
    cell t *grid = (cell t *)malloc(size);
    // Initial population
    srand(0);
    for (int i = 1; i <= N; i++)
        for (int j = 1; j <= N; j++)
            grid[IND(i, j)] = rand() % 2;
```

```
cell_t *d_grid, *d_newgrid;
double tmem = -wtime();
cudaMalloc((void **)&d grid, size);
cudaMalloc((void **)&d newgrid, size);
cudaMemcpy(d_grid, grid, size, cudaMemcpyHostToDevice);
tmem += wtime();
// 1d drids for copying ghost cells
dim3 block(BLOCK SIZE, 1, 1);
dim3 cols_grid((N + block.x - 1) / block.x, 1, 1);
dim3 rows_grid((N + 2 + block.x - 1) / block.x, 1, 1); \leftarrow
// 2d grid for updating cells: one thread per cell
dim3 block2d(BLOCK SIZE, BLOCK SIZE, 1);
int nblocks = (N + BLOCK_SIZE - 1) / BLOCK_SIZE;
dim3 grid2d(nblocks, nblocks, 1); ←
```

```
double t = wtime();
int iter = 0;
for (iter = 0; iter < ITERS MAX; iter++) {</pre>
    // Copy ghost cells: 1d grid for rows, 1d grid for columns
    copy_ghost_cols<<<cols_grid, block>>>(d_grid, N);
    copy ghost rows<<<rows grid, block>>>(d grid, N);
   // Update cells: 2d grid
    update_cells<<<grid2d, block2d>>>(d_grid, d_newgrid, N);
   // Swap grids
    cell_t *p = d_grid; d_grid = d_newgrid; d_newgrid = p;
cudaDeviceSynchronize();
t = wtime() - t;
tmem -= wtime();
cudaMemcpy(grid, d_grid, size, cudaMemcpyDeviceToHost);
tmem += wtime();
```

```
__global__ void copy_ghost_rows(cell_t *grid, int n)
   int i = blockIdx.x * blockDim.x + threadIdx.x;
   if (i <= n + 1) {
       // Bottom ghost row: [N + 1][0..N + 1] <== [1][0..N + 1]
       grid[IND(N + 1, i)] = grid[IND(1, i)];
       // Top ghost row: [0][0..N + 1] <== [N][0..N + 1]
       grid[IND(0, i)] = grid[IND(N, i)];
__global__ void copy_ghost_cols(cell_t *grid, int n)
   int i = blockIdx.x * blockDim.x + threadIdx.x + 1;
   if (i <= n) {
       // Right ghost column: [1..N][N + 1] <== [1..N][1]
       grid[IND(i, N + 1)] = grid[IND(i, 1)];
       // Left ghost column: [1..N][1] <== [1..N][N]
       grid[IND(i, 0)] = grid[IND(i, N)];
```



```
__global__ void update_cells(cell_t *grid, cell_t *newgrid, int n)
{
    int i = blockIdx.y * blockDim.y + threadIdx.y + 1;
    int j = blockIdx.x * blockDim.x + threadIdx.x + 1;
    if (i <= n && j <= n) {
        int states[2][9] = {
            {0, 0, 0, 1, 0, 0, 0, 0}, /* New states for a dead cell */
            {0, 0, 1, 1, 0, 0, 0, 0} /* New states for an alive cell */
        };
        int nneibs = grid[IND(i + 1, j)] + grid[IND(i - 1, j)] +
                     grid[IND(i, j + 1)] + grid[IND(i, j - 1)] +
                     grid[IND(i + 1, j + 1)] + grid[IND(i - 1, j - 1)] +
                     grid[IND(i - 1, j + 1)] + grid[IND(i + 1, j - 1)];
        cell t state = grid[IND(i, j)];
        newgrid[IND(i, j)] = states[state][nneibs];
```

size t total = 0;

for (int i = 1; i <= N; i++) {</pre>

```
for (int j = 1; j <= N; j++)
        total += grid[IND(i, j)];
printf("Game of Life: N = %d, iterations = %d\n", N, iter);
printf("Total alive cells: %lu\n", total);
printf("Iterations time (sec.): %.6f\n", t);
printf("GPU memory ops. time (sec.): %.6f\n", tmem);
printf("Iters per sec.: %.2f\n", iter / t);
printf("Total time (sec.): %.6f\n", t + tmem);
                                             Cluster Oak / cngpu1 (GeForce GTX 680)
free(grid);
                                      Game of Life: N = 1024, iterations = 1024
cudaFree(d_grid);
                                      Total alive cells: 47026
cudaFree(d newgrid);
                                      Iterations time (sec.): 0.911321
return 0;
                                      GPU memory ops. time (sec.): 0.238265
                                      Iters per sec.: 1123.64
                                      Total time (sec.): 1.149586
                                                                     Speedup 1.99
```

Peaлизация на CUDA v2 (2_gol_cuda_constant)

```
__constant__ int states[2][9] = {
   {0, 0, 0, 1, 0, 0, 0, 0}, /* New states for a dead cell */
   {0, 0, 1, 1, 0, 0, 0, 0} /* New states for an alive cell */
__global__ void update_cells(cell_t *grid, cell_t *newgrid, int n)
    int i = blockIdx.y * blockDim.y + threadIdx.y + 1;
    int j = blockIdx.x * blockDim.x + threadIdx.x + 1;
    if (i <= n && j <= n) {</pre>
        int nneibs = grid[IND(i + 1, j)] + grid[IND(i - 1, j)] +
                     grid[IND(i, j + 1)] + grid[IND(i, j - 1)] +
                     grid[IND(i + 1, j + 1)] + grid[IND(i - 1, j - 1)] +
                     grid[IND(i - 1, i + 1)] + grid[IND(i + 1, i - 1)];
       cell t state = grid[IND(i, j)];
       newgrid[IND(i, j)] = states[state][nneibs];
```

Peaлизация на CUDA v2 (2_gol_cuda_constant)

```
__constant__ int states[2][9] = {
   {0, 0, 0, 1, 0, 0, 0, 0}, /* New states for a dead cell */
   {0, 0, 1, 1, 0, 0, 0, 0} /* New states for an alive cell */
__global__ void update_cells(cell_t *grid, cell_t *newgrid, int n)
   int i = blockIdx.y * blockDim.y + threadIdx.y + 1;
   int j = blockIdx.x * blockDim.x + threadIdx.x + 1;
   if (i <= n && j <= n) {
       int nneibs = grid[IND(i + 1, j)] + grid[IND(i - 1, j)] +
                    grid[IND(i, j + 1)] + grid[IND(i, j - 1)] +
                    grid[IND(i + 1, j + 1)] + Cluster Oak / cngpu1 (GeForce GTX 680)
                    grid[IND(i - 1, j + 1)] +
                                              Game of Life: N = 1024, iterations = 1024
                                             Total alive cells: 47026
       cell t state = grid[IND(i, j)];
       newgrid[IND(i, j)] = states[state][nnei Iterations time (sec.): 0.221800
                                              GPU memory ops. time (sec.): 0.231555
                                              Iters per sec.: 4616.77
                                              Total time (sec.): 0.453355 Speedup 5.0
```

CUDA GPU Occupancy Calculator

http://developer.download.nvidia.com/compute/cuda/CUDA Occupancy calculator.xls

В программе блоки 1d: 1x16

2d: 16x16

CUDA GPU Occupancy Calculator Click Here for detailed instructions on how to use this occupancy calculator. For more information on NVIDIA CUDA, visit http://developer.nvidia.com/cuda Just follow steps 1, 2, and 3 below! (or click here for help) Your chosen resource usage is indicated by the red triangle on the graphs. The other data points represent the range of possible block sizes, register counts, and to Capability (click): shared memory allocation. (Help) 1.b) Select sin Size Config (bytes) 49152 Impact of Varying Block Size 9 2.) Enter your resource usage: My Block Size 256 10 Threads Per Block (Help) 64 11 Registers Per Thread Multiprocessor Warp Occupancy 12 Shared Memory Per Block (bytes) (Don't edit anything below this line) 16 3.) GPU Occupancy Data is displayed here and in the graphs: 17 Active Threads per Multiprocessor 2048 (Help) 18 Active Warps per Multiprocessor 64 19 Active Thread Blocks per Multiprocessor 20 Occupancy of each Multiprocessor 100% 23 Physical Limits for GPU Compute Capability: 3,0 24 Threads per Warp 64 128 192 256 320 384 448 512 576 640 704 768 832 896 960 1024 25 Warps per Multiprocessor Threads Per Block 26 Threads per Multiprocessor 2048 27 Thread Blocks per Multiprocessor 28 Total # of 32-bit registers per Multiprocessor 65536 Impact of Varying Register Count Per Thread 29 Register allocation unit size 256 30 Register allocation granularity warp My Register Count 31 Registers per Thread 32 Shared Memory per Multiprocessor (bytes) 49152 33 Shared Memory Allocation unit size 256 cupancy 56 34 Warp allocation granularity 35 Maximum Thread Block Size 1024

Peaлизация на CUDA v2 (2_gol_cuda_occupancy)

```
enum {
    BLOCK_1D_SIZE = 1024, BLOCK_2D_SIZE = 32
};
int main(int argc, char* argv[])
    // 1d grids for copying ghost cells
    dim3 block(BLOCK 1D SIZE, 1, 1);
    dim3 cols_grid((N + block.x - 1) / block.x, 1, 1);
    dim3 rows_grid((N + 2 + block.x - 1) / block.x, 1, 1);
    // 2d grid for updating cells: one thread per cell
    dim3 block2d(BLOCK_2D_SIZE, BLOCK_2D_SIZE, 1);
    int nblocks = (N + BLOCK_2D_SIZE - 1) / BLOCK_2D SIZE;
    dim3 grid2d(nblocks, nblocks, 1);
    // ...
```

Peaлизация на CUDA v2 (2_gol_cuda_occupancy)

```
enum {
    BLOCK_1D_SIZE = 1024, BLOCK_2D_SIZE = 32
};
int main(int argc, char* argv[])
    // 1d grids for copying ghost cells
    dim3 block(BLOCK 1D SIZE, 1, 1);
    dim3 cols_grid((N + block.x - 1) / block.x, 1, 1);
    dim3 rows_grid((N + 2 + block.x - 1) / block.x, 1, 1);
                                                  Cluster Oak / cngpu1 (GeForce GTX 680)
    // 2d grid for updating cells: one the
                                           Game of Life: N = 1024, iterations = 1024
    dim3 block2d(BLOCK_2D_SIZE, BLOCK_2D]
                                           Total alive cells: 47026
    int nblocks = (N + BLOCK_2D SIZE - 1)
                                            Iterations time (sec.): 0.169622
    dim3 grid2d(nblocks, nblocks, 1);
                                           GPU memory ops. time (sec.): 0.238457
    // ...
                                            Iters per sec.: 6036.95
                                            Total time (sec.): 0.408079
                                                                          Speedup 5.7
```